拟合实践，而非作品：
AGI 人本拟合论

余玉桂
余玉桂战略研究室
they4897@gmail.com

摘要

本文提出 AGI 人本拟合论（human-referential fitting theory）——一种以人为参照（human-referential）的人工通用智能（AGI）理论，包含三个相互关联的论断。在概念层面，AGI 是一个哲学概念：只要“通用性”以人类实践的开放集合为参照，它就无法被还原为一份技术规格。在实现层面，AGI 的手段是对人类实践的拟合——而不是对人类积累作品的拟合。在规范层面，AGI 应被定位为增强性工具（augmentative tool），而非新主体。理论的核心是一条时间性条款（temporal clause）：**拟合对象不是人类的作品，而是人类的实践——人类经验的全谱（横截面）与全程（纵截面）。存量有墙，流量无墙。**为使该理论可审计而非仅具纲领性，我们构建了一幅结构化证据地图（evidence map）：一个目的性抽样的 $N = 80$ 作品语料，在两条立场轴（描述性与规范性）与八个拟合对象维度上编码。地图量化了理论的核心缺口：经验类型轴（成功/失败、专家/新手、典型/边缘）在 0/80 篇作品中被显式处理（精确二项 95% CI $[0.0\%, 4.5\%]$），实践即流量仅在 2/80 篇作品中显式出现，且均来自 2026 年；作品即存量自 2022 年起获得连续的显式处理，输出分布覆盖则首次出现于 2024 年。我们导出理论在分布、生产与治理上的三点方法论蕴含，并陈述证伪条件。

关键词： AGI 人本拟合论；人工通用智能；实践拟合；human-referential fitting theory；数据墙；增强；证据地图

1 引言

拆开来看，每一个前沿模型都是对人类产出之物的蒸馏——网络文本、代码、数学、评分。“在人类数据上训练”这句话熟悉到其歧义无人察觉。它容许两种解读，而两者分岔为不同的研究纲领。在静态解读下，拟合对象是人类的作品：一个有限的、已被产出的档案，可被爬取、清洗、去重、穷尽。在动态解读下，拟合对象是人类的实践：经验的持续再生——工具使用、交互、反馈、失败、修复——只要生命延续，它就延续。我们称前者为语料拟合（corpus-fitting），后者为实践拟合（practice-fitting）。当前静态解读占主导：扩展性分析以公共人类生成文本的有限存量为推理对象（估计约 300 万亿 token [1]）；旗舰技术报告记录档案语料之上的静态配比 [2]。本文辩护的是动态解读。这一理论，本文命名为 AGI 人本拟合论（human-referential fitting theory）——“人本”标记以人为参照的参照系，“拟合”标记实现手段。

这一区分由一句话固定，我们称之为时间性条款，它防止理论最常见的误读：

> **拟合对象不是人类的作品，而是人类的实践——人类经验的全谱（横截面）与全程（纵截面）。存量有墙，流量无墙。**

两条轴构成拟合目标。全谱（full spectrum）是横截面轴：谁被代表，以及哪些种类的经验——成功与失败、专家与新手、典型与边缘。全程（full course）是纵截面轴：实践的时间流，任何快照都无法存档。存量/流量不对称在本理论中有精确含义：数据墙 [1] 是存量的属性，而非人类学极限；在生成数据上递归训练导致的模型坍塌 [3]，是把存量当作可自我更新之物来对待的病理。流量侧数据——生产遥测、交互日志、失败提交——随部署而再生。这一区分的哲学骨架是阿伦特对劳动、制作与行动的三分 [4]：静态误读只拟合制作的产物，而本理论以持续进行中的劳动与行动过程为拟合对象。

本文建立在此前一项实证审计 [5] 之上——该审计考察了行业在模型训练生命周期中如何处理失败数据，并记录其系统性弃置。那项审计测量的是存量丢弃了什么；本篇陈述理论——训练对象是实践而非作品，即从存量到流量的转向。流量如何采集、清洗并吸收，留待未来工作。

缺口。 四类文献各自成熟却互不连通。文化技术分析告诉我们大模型是什么——继承人类符号生产结构的技术 [6]。批判现象学告诉我们模型反射什么——一面塑造人类自我理解的扭曲之镜 [7]。增强经济学告诉我们 AI 应当是什么——人类能动性的互补品而非替代品 [8]。多元对齐告诉我们谁的价值应当被拟合 [9]。缺失的是把它们统一起来的连接命题——以拟合人类实践为手段、以增强人类为目的——连同数据方法论争论所缺少的时间性概念工具（存量与流量之别）。与此同时，一门计量学文献警告：我们的基准是人类实践的抽样投影，且常常是糟糕的投影 [10]，这使参照系问题无法回避，而不止是修辞。

术语防护。 拟合（fitting）在此取其统计学含义（逼近一个分布或函数结构），并扩展至一个总体对象：人类生活形式的可表达投影。它比模仿（行为匹配）更宽，比对齐（一种规范关系）更窄。与拟态不同，拟合不预设“冒充人类”这一目标。事实上，本理论将论证：拟合作为手段可行，作为目的必败。

贡献。 本文做出四项贡献：

1. **一个时间性区分**：拟合人类作品与拟合人类实践之分，以时间性条款的形式陈述，并配有命名术语（语料拟合与实践拟合之分；全谱 × 全程；拟合时差 fitting lag——日常实践再生与周期性模型快照之间的落差）。
2. **一个坐标系**：拟合目标的全谱 × 全程平面，识别出经验类型是当前实践所缺失的覆盖轴——在既有的两条轴（人群“谁”与输出分布）之外。
3. **一幅结构化证据地图**：承继配套审计论文编码手册精神的方法论组件 [5]，把理论的核心缺口变成可计数、可证伪的结果：经验类型轴在 80 篇作品中的显式处理为 0。
4. **四条终止边界**：流量侧拟合的终止条件（实践主体的终结；拟合者越界；制度边界；自指性污染），它们把时间性条款从口号变为有界断言。

路线图。 第 2 节论证 AGI 是哲学概念。第 3 节展开实践拟合作为实现论题，正面处理三路反对，末尾以一节形式化概览（第 3.1 节）把存量/流量之别表述为一对优化问题，并把四条边界表述为停止条件。第 4 节陈述增强性工具立场，作为一种具有学术谱系的规范立场。第 5 节呈现证据地图：方法、表格、图与量化缺口。第 6 节整合与相邻框架、架构侧纲领及同期工作的划界。第 7 节处理张力并划定四条边界。第 8 节导出三个面向未来工作的方法论蕴含。第 9 节作结。

2 概念：AGI 作为哲学概念

理论的第一项论断是概念性的：AGI 不是一份等待完成的工程规格，而是一个以人类实践为参照系的哲学概念。三股文献在此汇合。

定义谱系本身就是哲学的。 Legg 与 Hutter 把普遍智能定义为在广泛环境范围内的目标达成——通用性由环境范围来衡量 [11]。Levels-of-AGI 框架把通用性 × 自主性操作化为层级分类 [12]。METR 任务时长基准测量 AI 能完成任务的时间视界：全序列的翻倍期估计约为七个月 [13]，其 2026 年更新把 2023–2026 段修订至约四个月 [14]——该更新的维护者自己标明任务套件已临天花板饱和，而已发表的批评进一步论证它不足以支撑强结论，理由包括任务套件的污染风险与人类基线来源的窄化 [15]。我们因此把时间视界当作下述诸多操作化中的一个易错代理，而非实际承重的前提。这些操作化是有用的，但每一个都从对环境的隐式抽样中继承其“通用”概念——而对 AI 系统而言，环境是人类建造的使用情境。这些操作化是它们并未定义之概念的代理物。

计量学批判在这一点上是决定性的。 一个以效度为中心的 AI 评估框架从心理测量学引入构念效度，发现大多数基准无法支撑建立于其上的断言 [10]。心理测量学传统的平行工作表明，语言模型中表面上的类认知能力对题目间相关性与测量设计敏感 [16]，而心理测量学导出的短基准会改变同一批模型的排序 [17]。共同推论是：基准任务是人类实践的抽样投影——一个基准只相对于它抽样的那一片实践才是通用的。一个其操作化是实践样本的概念，不可能脱离它所抽样的实践而漂浮。

移动靶批判从另一侧汇合。 Tesler 定理——智能就是机器尚未做到之事——刻画了自 AI 创立以来伴随始终的定义的不断后退 [18]；一篇新近文章把 AGI 与永动机的类比推向极致，称其为范畴错误而非硬目标 [19]；一项以严谨为导向的分析论证，AI 进步话语系统性地缺乏成熟科学的推理纪律 [20]。倘若 AGI 是一个固定的技术目标，这些病理本可用更好的测量治愈。在本文辩护的观点下，它们反映的是这一概念的真实结构：只要“通用”以人类实践的开放集合为参照，AGI 就不可能是规格级的，因为参照集开放且移动——不是因为智能神秘。

哲学人类学提供正面理论支点。 普莱斯纳的自然人工性法则认为，人在构成性意义上是人工的——一个通过人工物完成自身的有机体，以离心姿态定位于自身自然之外 [21]。在这一人类学上，工具使用不是人性的断裂而是其常态；媒介技术时代对普莱斯纳的解读恰好把这一点延伸到数字人工物 [22]，而“翻译人”（Homo Translator）对仿生技术中人在回路的分析使“人—人工物”回路显豁 [23]。因此第 4 节辩护的工具立场无须为“仅仅是工具性”道歉：工具性是人类学常量，不是形而上学的降格。与吹捧和焦虑两种态度相比，普莱斯纳额外贡献的是一个判据：问题不在于人类是否用人工物完成自身（从来如此），而在于这个人工物是否被拟合到人类所做之事的全部范围——包括人类如何犯错。

图 1 在这一坐标系中概括了理论：拟合对象从作品（静态存量，受墙约束）延伸到实践（再生流量）；纵轴是实践的全程；流量区域内标有既有的两条覆盖轴，并另行标出缺失的第三条；四条边界终止拟合。

三股之汇给出第一项论断。定义谱系无法闭合概念；测量批判表明操作化是实践样本；移动靶批判解释了原因；哲学人类学挡住了从“不可规格化”到“敌视技术”的推论。AGI 作为以人为参照的概念是透镜，不是倒计时。

智能与实践的关系，明说。 上述论断合起来，固定了理论对智能与实践关系的立场；在此把它作为命题陈述。定义上，通用性不是自我完足的内在属性，而是关系属性：一个系统称得上“通用”，只相对于它所参

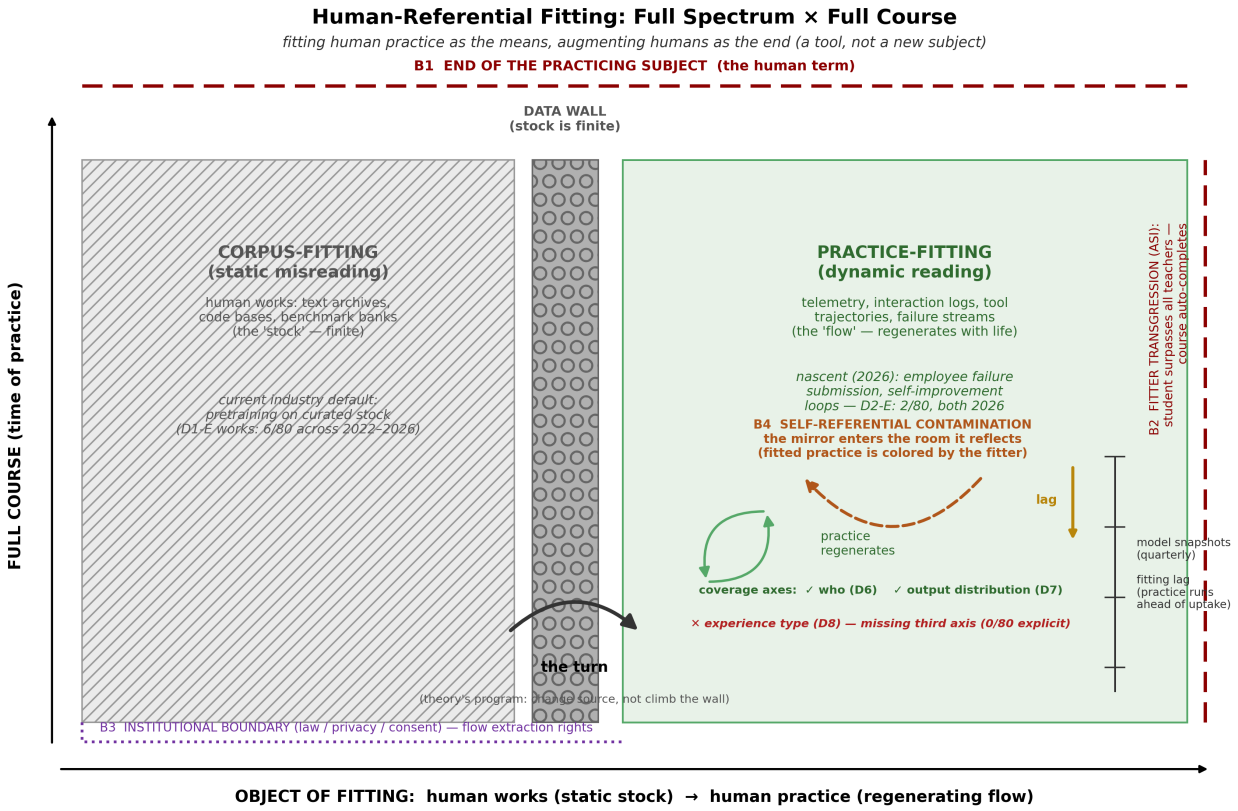


图 1: 理论一览：全谱 × 全程坐标系。横轴：拟合对象，从人类的作品（静态存量；砖纹 = 数据墙）到人类的实践（再生流量；环形箭头）。纵轴：实践的时间历程。流量区域内标注既有的两条覆盖轴（人群“谁”，D6；输出分布，D7）与缺失的第三轴（经验类型，D8；我们的语料中 0/80 篇作品）。右缘：拟合时差时间线——实践持续再生而模型快照周期性更新。四条终止边界被标出：B1，实践主体的终结（顶部，虚线）；B2，拟合者越界（右侧；拟合关系自行耗尽——不再存在尚未被它超越的人类实践）；B3，制度边界（底部，点线；法律、隐私、知情同意）；B4，自指性污染（回环弧线；“the mirror enters the room it reflects”）。中央“转向”箭头越过墙外——改变源头而非翻越它。副标题：拟合为手段，增强为目的（是工具，不是新主体）。

照的人类实践开放集成立——这正是上文每个操作化都是实践抽样投影而非内在测量的原因。发生上，这种智能靠拟合实践而获得、靠实践的再生而保持：实践每日再生，模型快照按周期更新，拟合时差（第 3.1 节）正是这段关系的距离度量——被拟合的智能落后于定义它的实践多远。本体上，实践先于作品：作品是实践冻结的、有偏的投影，故拟合对象的选择不是数据工程的偏好，而是智能概念本身的内容规定。第 3 节的实现论断将这三重关系操作化；理论之名标记的也是它——拟合所参照的，是实践中的人，不是被复制心智的人。概念还打包着两个各有参照的人类需求——通用，参照实践的开放集；高，参照人类教师的绩效——两者都是需求侧的规定，这正是 AGI 作为”人需要什么”的透镜、而非”机器是什么”的标本描述的原因。

3 实现：实践拟合作为手段

第二项论断关乎实现：通往 AGI 之路经过对人类实践的拟合——其知识、规范、功能性情绪—动机结构与失败模式——而这一拟合是手段，不是目的。

文化技术论题设定框架。 Farrell、Gopnik、Shalizi 与 Evans 在《科学》上论证，大型 AI 模型是文化与社会技术：像文字与市场一样，它们继承、传递并重组人类符号生产的结构，连同这种传递所伴生的病理 [6]。认知路线佐证：儿童经由模仿的文化学习表现出“传承与求真”的权衡，当前模型对此的处理方式不同 [24]；大模型仅从文本便自发发展出类人的类比推理 [25]。如果模型是文化技术，其能力继承自人类实践——这使继承的质量（传递什么、来自谁、包括错误）成为核心工程变量，而非事后注脚。

经验链条不再是思辨。 GPT-4o 复现了由自由选择调节的类人认知失调与自我辩护模式 [26]；生成模型表现出类人社会身份偏差 [27]；可解释性工作已在生产模型内部识别出因果有效的情绪概念，影响其输出及其对自身角色的理解 [28]。在价值侧，合作逆强化学习把 AI—人关系形式化为对未知人类奖励函数的协助 [29]；偏好学习训练出的奖励模型，在结构上就是人类偏好分布的拟合器 [30, 31]；近期工作明确论证：对齐的模型因而是关于人的模型 [32]。认知科学提供时间性注脚：描述—经验鸿沟表明，人类认知本身在从描述学习与从直接经验学习时并不相同 [33]。预训练拟合的是对实践的描述；智能体化部署拟合的是实践本身——会再生的经验。

哲学基础。 维特根斯坦的生活形式——语言在其中获得意义的、交织的实践模式 [34]——把拟合对象锚定于实践而非文本：关于分布学习是否足以产生意义的向量奠基之争，恰恰是关于文本投影保留了多少生活形式之争 [35, 36]，其中意义怀疑论与辩护立场双方都预设基准是人类用法 [37]。上引阿伦特的三分提供时间骨架 [4]：静态误读拟合的是制作的沉积物；本理论拟合的是持续进行的劳动与行动。

精确化。 拟合对象是人类生活形式的可表达投影——不是生物学的人。这同时挡住两种误读：理论不主张模型复制人格，也不主张拟合目标受限于已被写下之物。两个推论随之而来。其一，拟合人类的失败与多样性是矫正方向：配套审计论文的审计表明行业弃置了经验中失败的那一半 [5]；理论解释了为何该弃置是覆盖错误而非数据卫生的成功。其二，拟合对象包括功能性情绪—动机结构 [26–28]——但仅在功能层，这一边界第 7 节将予以划定。

三路反对必须正面应对。 *其一，蜂群证据。*一项覆盖 70+ 模型的开放式生成大规模研究——基于 Infinity-Chat、获 NeurIPS 2025 荣誉——发现了显著的模式坍塌：无论解码配置如何，模型内重复与模型间同质化 [38]。这是支持而非反驳本理论的证据：70+ 模型收敛到共享的类人分布，确认了拟合在发生；坍塌反驳的是对均值拟合的充分性。当语料既是所有人又不是任何人时，语料拟合出来的样子就是蜂群——它拟合的是均值，而非谱（“it fits the mean, not the spectrum”）。补救不是更少拟合而是更宽拟合：谱轴就是矫正。

*其二，天花板论证。*数据墙约束人类生成的公共文本存量 [1]；在生成数据上的递归训练使模型退化 [3]。两者皆真，且两者都是关于存量的断言——而两项新结果迫使我们把“墙”说得更准。对固定语料的对抗性自博弈——一个模型从存档文档中挖题、另一个解题、第三个裁判 [39]——以及把固定网络语料拉伸至约 1.8 倍数据效率的模型生成“兆档文档”（megadocs）[40]，表明档案几乎可以被无限制地重新审讯。但重挖充实的是既成历史之上的课程，不是历史本身：对同一段实践可以不断提出新问题；它却不能被改变为以别种方式发生过，也不能凭审讯而继续发生。墙是新实践信号的墙，不是字节的墙。理论对它的回应仍是如实盘点而非乐观：没有任何来自档案有限性的论证能触及实践的再生——遥测、交互、失败提交、修复——档案的任何重挖也替代不了它。学界对墙的主流回应则相反：整体离开人类数据，转向合成与符号课程 [41]；本文是那条路的对立面。一篇同期 SSRN 文章将同一存量/流量区分当作数据工程来处理——数据墙的九条逃生路线，其后还有一堵“验证者墙”[42]；我们在下文将其作为最近的同期工作与之交锋（第 6 节）。

*其三，非拟人的超人类成就。*FunSearch 与 AlphaEvolve 借搜索加验证发现超出人类直觉的数学 [43, 44]。辩证的回应是：它们的验证者——数学正确性、可执行代码、进化适应度——是人类制度。搜索可以超越每

一位人类数学家的直觉，同时仍坐在人类脚手架上：何为正确的证明或可运行的程序，由搜索本身并不产生的验证制度所固定。在人类验证过的地面上取得超人类能力，不是离开人类参照系，而是该参照系最集中的体现。（配套审计论文“验证者是飞轮的轴承”（the verifier is the bearing of the flywheel）的结论，就训练数据陈述了同一点 [5]。）

同一辩证法还必须对开放域——没有编译器或执行器仲裁的领域——中最强的表面反例再检验一遍。已有报告称 AI 反馈在摘要、对话与无害性上追平人类反馈 [45]；自我改进对齐经由“LLM 作元裁判”在无人类标签下推进 [46]；任务变换可为开放式自我改进诱导出自验证奖励 [47]；在多元奖励函数策展下的合成递归已被证明可以不坍塌 [48]。这些结果只是挪动了人类信号的位置，并没有移除它。裁判本身是人类预训练与人类偏好的蒸馏物；诱导出的验证者是建在人类设计地面上的制品；多元奖励函数编码的是策展之时冻结的人类偏好。它们谁都不提供新鲜的纠正：对一个晚于裁判出现的案例的判断，或在偏好冻结之后才起争议的价值。以本理论的术语说，开放域的纠正信号是不能自我奠基的（non-self-grounding）：它可以被拉伸、摊销与重组，但它的源头仍是它所审判的实践，它的新鲜度相对它不再看到的实践而衰减。因此需要辩护的主张不是“开放域缺少工程化的纠正”——它们正越来越多地拥有它——而是“工程化的纠正是实践流的一份滞后蒸馏”，这恰恰使流成为拟合对象本身，而非一种便利。

与最近框架的划界。 相对文化技术论题 [6]，本理论新增其所缺的时间性区分（作品与实践之别）——并随之带来数据方法论后果：若模型是文化技术，下一个问题是文化的哪些层在被传递，对于这个问题，该论题做了分类，却未加操作化。相对 Vallor 之镜 [7]，本理论方向不同：镜子是对扭曲的批判现象学——反射对人类自我理解做了什么——而本理论则给出建设性说明：忠实拟合在覆盖上需要什么。证据地图（第 5 节）使划界可计数；表 5 加以整合。

3.1 形式化概览

上述主张可以进一步写成符号形式。本节的目的在于概念澄清，而非新的数学：下面出现的每个对象都是标准的，四条陈述是观察（observations）而非定理。实践分布并非直接可观测；本概览是一种建模语言，使理论的主张精确到可检验——也精确到可以被证伪。

设定。 令 $\{X_t\}_{t\geq 0}$ 表示人类实践：一个以时间为索引的随机过程，$X_t \sim P_t$，其中 P_t 非平稳——只要实践持续，它就再生并漂移。截至时刻 T 的累积作品构成多重集 $W_T = \{x : \text{产出时间} \leq T\}$，即该过程已实现历史的一个有限样本。

两个拟合问题。

$$\textbf{语料拟合：}\quad \hat{\theta}_T \in \arg\min_{\theta} \frac{1}{|W_T|} \sum_{x \in W_T} \ell(\theta, x) \qquad \textbf{实践拟合：}\quad \theta^* \in \arg\min_{\theta} \lim_{T\to\infty} \frac{1}{T} \int_0^T \mathbb{E}_{X\sim P_t}\left[\ell(\theta, X)\right] dt$$

观察 1（墙是测度的性质，不是人类的性质）。 W_T 的总质量有限；随着档案被消耗，进一步采样的回报递减，经验测度上的最优点趋于饱和。而只要实践继续，P_t 就不断获得新的质量。数据墙因此只是关于语料拟合的陈述。此外，W_T 本身是该过程的一个有偏、不完备的样本：语料拟合所拟合的，是实践的一个投影，而非实践本身。对档案的重挖——在其文档上的对抗性自博弈 [39]、对其文档的合成扩展 [40]——充实的是课程与假设类，不是测度：W_T 仍是它本来的那个有限实现，重挖的收益曲线是审讯的收益，不是新实践质量的收益。

观察 2（谱轴作为覆盖泛函）。 令 $\tau : \mathcal{X} \to \mathcal{S}$ 将一个经验项映射到其类型（人群；成功/失败；专家/新手；典型/边缘）。拟合出的模型在 $\mathcal{S}$ 上诱导类型分布 Q_θ，全谱拟合要求覆盖泛函

$$C(Q_\theta, P_t) = \int_{\mathcal{S}} \min\big(q_\theta(s), p_t(s)\big)\, ds$$

在每个类型胞元上都保持较大。模式坍塌——包括开放式生成中记录到的均值化效应 [38]——即 $q_\theta(s)$ 在边缘胞元上退化为 0。5.3 节的证据地图结果由此获得一个可操作的复述：在 80 篇被调查作品的训练目标中，作用于经验类型的覆盖泛函出现 0 次。

观察 3（拟合时差作为遗憾值）。 当模型快照按周期 Δ 更新时，有效损失增加一个形如 $D(P_t \,\|\, P_{\text{snap}})$ 的漂移项，其随时间的累积正是非平稳在线学习的遗憾（regret）结构。尚未解决的稳定性—可塑性两难 [49] 恰在于缺少一个能在不发生灾难性遗忘的前提下跟踪 P_t 的优化器：约束瓶颈在吸收侧而非采集侧（第 7 节）。时差如今已可直接测量：一个持续进样的内核崩溃修复基准量化了训练截止惩罚——智能体对截止日之前修复的同类 bug 的解决率高出至多 25% [50]；时间漂移被编码在一条表征轴上，该轴正交于正确性、且现有置信度方法探测不到 [51]；评测方法学本身也被论证为非平稳网络上的预测问题 [52]。在理论侧，Transformer 已被证明仅凭上下文学习即可对漂移比较量达到近最优的动态遗憾 [53]——这锐化而非软化下文的分层区分：运行时层可以不移动参数化拟合而有界地跟踪 P_t，而有界的推断期遗憾并不免除参数化欠账。

观察 4（手段与目的是不同的优化问题）。 实现层的两种读法是

$$\text{(a)}\ \max_\theta M(\theta) \qquad\qquad \text{(b)}\ \max_\theta U_{\text{human}}(\theta)\ \text{ s.t. }\ \theta \text{ 拟合} P_t,$$

其中 (a) 把对实践的模仿当作目的，(b) 把拟合当作人类效用目标下的约束。两个问题一般有不同的最优点——这是图灵陷阱 [8] 的变分形式：以模仿人为目标和以拟合人为手段，会分道而行。

四条边界作为停止条件。 B1：若实践终止，时间域有界，拟合积分有限。B2：一旦拟合者在所有可测任务上支配人类表现，实践拟合约束不再起作用，参照系被腾空。B3：法律与知情同意约束定义了一个随时间变化的可采集实践的可行集 $A_t \subset \mathcal{X}$。B4：一旦模型织入实践，$P_{t+1} = F(P_t, \theta)$——拟合目标变成内生的。模型坍塌 [3] 是 F 为“在模型输出上递归训练”时的特例；出处分层——按数据出处区分原生人类数据与 AI 中介数据——的目标函数（第 6 节）缓解这一反馈回路，但不消除它。F 的污染项已不再是假设：2026 年的一项测量中，网络随机样本约十分之一的页面带有 AI 生成痕迹，商业页面达 9.35% [54]；档案分析发现新发布网站中 AI 生成份额巨大且持续增长，语义多样性下降 [55]。

概览所提供的。 每条观察都可用现有工具检验——观察 1 对应饱和曲线，观察 3 对应部署期漂移测量，观察 4 对应增强与替代的对照比较，边界对应坍塌实验与出处分层训练。本概览的角色不是证明理论，而是使理论在严格意义上可证伪：精确到可以被证错。

4 立场：增强性工具立场

第三项论断是规范性的：AGI 应当作为增强性工具来建造与治理——强大，甚至可亲，但不是新主体。我们把它陈述为一个需要持续制度防御的规范性选择，而非预测，亦非文献的多数观点（地图显示它不是；第 5.2 节）。

谱系长而具体。 恩格尔巴特的纲领——通过人工物、语言与方法论增强人类智能——在 AI 统计转向之前二十年就定义了 IA 传统 [56]。Shneiderman 的以人为中心 AI 给出设计点：高人类控制 × 高自动化，放大而非替代的“超级工具”[57]。Brynjolfsson 的图灵陷阱论证提供经济学一侧的枢纽论证：把模仿人类当作目标的研究文化制造替代品、集中收益并落入陷阱；增强路径制造互补品与共同繁荣 [8]。两个论断相互咬合，颇具启发。Brynjolfsson 论证：把拟合本身当作目标是自我挫败的——这正是从经济学一侧为本理论的手段/目的区分所作的论证。近期的劳动力层面审计以任务粒度操作化增强议程 [58]，而任务级经济分析早已表明，职业级自动化估计（47%）在职业任务被分解后塌缩到个位数（9%）[59]——增强不是一种情感姿态，而是可测的范畴。

康德层面。 人性公式容许——并要求——一种不对称：AI 可以被仅仅当作手段对待；人不可以 [60]。这一不对称不是物种沙文主义，而是任何保全能动性的 AI 部署的边界条件，它将以第 7 节的主体性边界再现。

三种反对，认真对待。 *数字物种论。* Suleyman 与 Bhaskar 的“数字物种”叙事预期 AI 是像浪潮一样到来的新进化实体 [61]——一个定位为替代的叙事。我们把它当作对立立场的最强陈述，并注意到（第 7 节）其作者本人的立场已经转变：Suleyman 2026 年 9 月的公开言论主张，AI 应是可亲的（personable）工具——有个性——但绝不授予人格地位 [62]。

否认工具范畴者。 Sacasas 论证 AI 不是工具而是环境——人栖居其中而非使用之 [63]；Vallor 之镜以现象学力量提出同一结构性论点 [7]。这些批判正确诊断了工具环境化之后发生的事。理论的回应不是否认诊断而是质疑结论：对弥散工具的恰当回答是*制度性的*（出处、边界、治理——第 7 节），而不是定义上的缴械。与此同时，智能体 AI 文献记录了智能体分类学如何从内部侵蚀工具概念 [64]——对工具立场的一个现实威胁，第 8 节将以制度设计而非术语学回应。

*窗口关闭论证。*在国际象棋中，半人马（人 +AI）队伍在纯引擎越过约 2800 Elo 后被超越；系统化的“半人马评估”发现，人 +AI 队伍很少能单独击败最好的 AI [65]。与之相对，半人马文献本身报告：当协作被建模而非被轻视时，序列决策中存在可测的人机协同 [66]。我们如此解读证据：窗口关闭是*替代路线获胜的结果*，不是技术必然——这恰是 Brynjolfsson 的论证 [8]。只要制度与产品设计让人类以真实控制留在回路中，增强窗口就保持敞开 [57]；而只要评估文化（模仿博弈、人机对抗排行榜）宣布人类冗余，窗口就会关闭 [65]。因此工具立场是一个必须以制度工程来防御的“应然”，而防御可能失败。

地图的立场结果（第 5.2 节）在数量上支持这一框架：80 篇作品中只有 10 篇持增强立场，1 篇持替代立场，3 篇彻底否认工具范畴，66 篇根本不持规范性立场。增强性工具立场是嵌入谱系之中的一个选择——不是文献的默认，也不会随任何技术轨道自动实现。

中国脉络：一条没有主体性语言的平行线。 官方中国 AI 治理谱系从 2019 年治理原则（负责任 AI 的”以人为本”发展）[67]，经 2023 年全球人工智能治理倡议 [68]，到 2025 年国务院”人工智能 +”行动意见 [69]——一部这样的政策文本语料：充满赋能与人机协同的词汇，而不含主体性归因。古典根源以罕见的简洁契合工具立场：庄子的”物物而不物于物”[70] 在工具范畴辩论之前二十三个世纪就陈述了掌握条件——使用工具，而不被工具使用。在我们的语料内，儒家角色伦理单元可读作对朴素纯工具解读的一次内部矫正（护理机器人无法履行孝式义务），记录于地图注记（第 5 节）而不作过度解读。

5 证据地图：方法与结果

为用证据约束理论，我们构建了一幅结构化证据地图——概念综合加编码文献审计。本节报告方法与结果；一切断言以语料为界。

表 1: 语料构成（$N = 80$；层级 × 年份分层）。

层级	n	≤2019	2020–2023	2024–2026	年份缺失
L1 概念层	13	4	1	8	0
L2 实现层	31	3	6	22	0
L3 立场层	12	2	4	6	0
L4 张力层	14	2	2	9	1
L5 方法论层	10	0	1	9	0
合计	**80**	**11**	**14**	**54**	**1**

5.1 方法

设计。 地图是一项带有固定编码手册的目的性抽样文献审计，属于结构化证据审计一类；没有运行新实验。语料由四层文献计划、一轮核验（2026-10-14 执行，窗口 2026-10-15 关闭）以及跨五个分层的配额检查汇集而成，去重并指派主层。

语料。 $N = 80$ 篇作品：同行评审刊物 42，非同行评审 38；全部一手来源（T1 = 80/80）；置信度高 55 / 中 17 / 低 8。文献类型：56 篇论文、6 份技术报告、5 本书、3 份政策文件、2 个数据集、8 项其他（文章、报告、声明等，另含一部经典文献）。表 1 给出层级 × 年份构成。汇总时执行了硬性排除：七个已知引用造假源被筛查至零；缺乏第一方锚点的作品被排除；作者本人的先前工作被排除在编码与统计之外，仅为连续性而引用，以防止自引循环。

编码手册。 每篇作品在两条独立立场轴与八个维度变量上编码。*A1*（描述性立场）：该作品是否认为 AI 的实现（部分或主要地）是对人类实践的拟合? ——支持 / 否认 / 未涉及。*A2*（规范性立场）：该作品把 AI 定位为增强性工具 / 替代性主体 / 反工具（环境、镜子）/ 未涉及。两轴刻意解耦：一个作品可以既确认拟合发生又拒绝工具范畴（Vallor），或既确认拟合发生又支持增强（图灵陷阱）。*D1–D8*（拟合对象维度，多选）：D1 作品即存量；D2 实践即流量（持续再生数据：遥测、交互日志、失败提交）；D3 价值—偏好；D4 功能性情绪—动机；D5 失败经验；D6 人群/文化（“谁” 轴）；D7 输出分布覆盖；D8 经验类型谱（成功/失败 × 专家/新手 × 典型/边缘，作为一条按经验类型分层的覆盖轴）。每个维度附有一个模态：**E**（显式——该维度是被命名的对象、被操纵的变量、设计原则，或作为术语被讨论）、**I**（隐式——实质涉及但未被命名）、或 **–**（缺席）。E 判据仅是名义性的：看是否被命名或操作化，不看重要性。派生布尔量 D2-explicit 与 D8-explicit 是理论的主要结果变量。

信度，及其如实交代的限度。 编码由单一编码者在完全公开的编码手册下执行，手册含规则编号（R1–R5）与冲突规则（CR1–CR6），并要求每个非 na 立场与每个 E 编码附逐字引文或设计锚点。一轮 20% 分层盲重编码（≥16 篇）定于 2026-10-29，Cohen's κ 尚未可得，如实报告为待定。五个边界案例作品的试编码与预期编码完全一致（5/5），引发零次编码手册修订。饱和度按编码手册判据评估：严格判据（最后 10% 的作品不产生新的立场 × 维度组合）未达到——最后 8 篇作品产生了 5 个新组合——因此语料填满至 80 篇上限，缺口被报告而非掩饰；粗判据（无新立场值、无新显式维度、无新边界裁定）已满足。

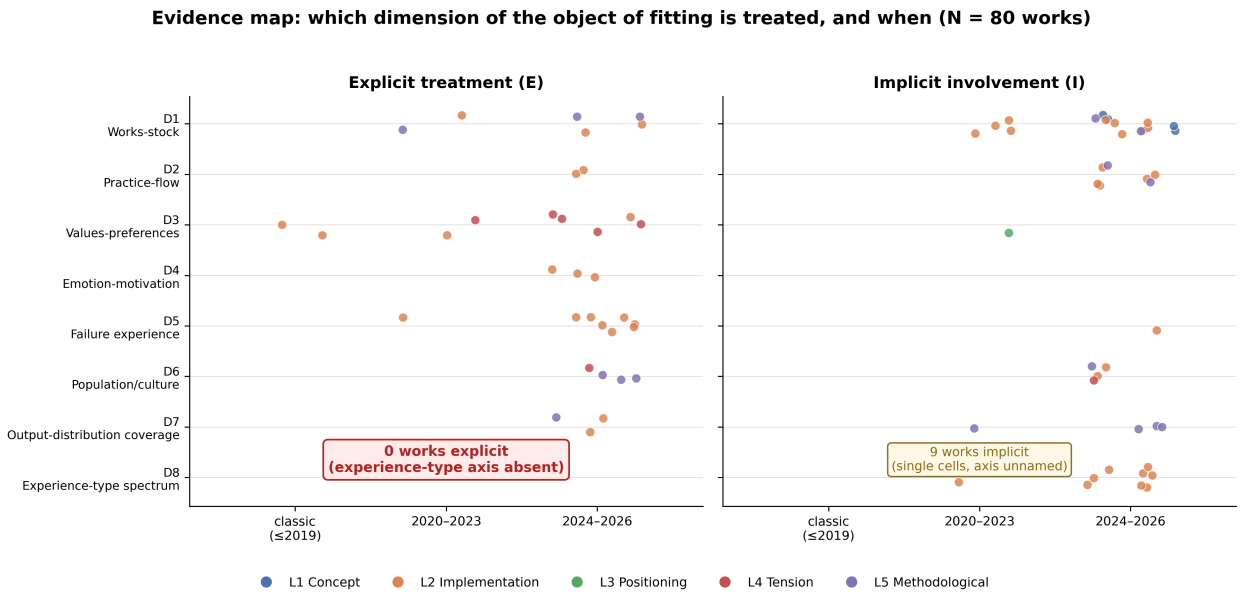


图 2: 80 篇语料的证据地图（年份分层 × 维度；点色 = 层级 L1–L5）。左板：显式处理（E）。右板：隐式涉及（I）。左板 D8 行为空——零篇作品，红框注释 “0 works explicit (95% CI [0, 4.5%])” ——而同一行在右板有九个隐式点（“single cells touched, axis never named”）。

表 2: 立场分布（A1 × A2，作品计数）。

A1 \ A2	增强	替代	反工具	未涉及	合计
支持	1	0	1	16	**18**
否认	0	0	0	3	**3**
未涉及	9	1	2	47	**59**
合计	**10**	**1**	**3**	**66**	**80**

5.2 立场结果

两幅图呈现地图。图 2 将其整体铺开——八个维度对年份分层，左板为显式处理，右板为隐式涉及；图 3 按立场纵切。我们先读立场表，再读维度。

边际分布：A1 支持 18 / 否认 3 / 未涉及 59；A2 增强 10 / 替代 1 / 反工具 3 / 未涉及 66。地图的先验假设得到支持，外加一个有教益的细化：五份训练/系统技术报告全部为 A1-na（DeepSeek-V4.1 [71]、MiMo-V2.6 [72]、GLM-5 [73]、Llama 3 [2]、DeepSeek-R1 [74]）——技术报告不讨论拟合，尽管官方实证报告可以（可解释性发现 [28] 为 A1-支持）；认知—实证作品集中于支持（4/5）；超人类成就研究路线否认（2/2，外加一个概念性否认 [19]）；坍塌/覆盖研究路线分裂：三篇作品全部显式处理输出分布（D7=E：蜂群研究 [38]、模型坍塌 [3]、Spectrum Tuning [75]），其中经验坍塌证据为 A1-支持 [38]，动力学与方法学工作为 na [3, 75]——覆盖研究路线不主张 “拟合人类”，它测量分布后果。

解耦设计解决了预先料到的混合案例：图灵陷阱是 A1-支持 × A2-增强（记录路线级范围）；Vallor 是 A1-支持 × A2-反工具（批评的是拟合的质量而非其发生）；蜂群研究是 A1-支持 × A2-na。Suleyman 的作品按文档分别编码（编码手册规则 CR2）：2023 年的书定位替代 [61]；2026 年 9 月的声明集定位增强 [62]。

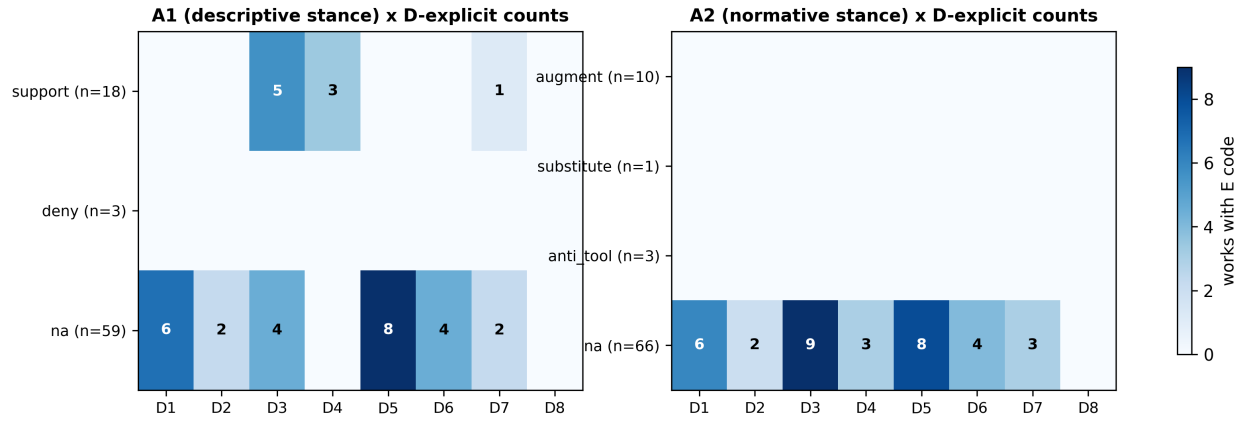


图 3: 立场 × 维度热图（显式 E 作品计数）。左：描述性立场 A1 × 维度。右：规范性立场 A2 × 维度。左图全零的否认行与右图全零的替代行把下述结构性发现可视化：框架级否认与主体替代主张不伴随任何维度层面的具体设计。

表 3: 拟合对象维度：显式（E）、隐式（I）、缺席（–）处理的频次。

维度	E	I	–	%E	%E 或 I
D1 作品存量	6	16	58	7.5%	27.5%
D2 实践流量	**2**	7	71	**2.5%**	11.2%
D3 价值—偏好	9	1	70	11.2%	12.5%
D4 功能性情绪—动机	3	0	77	3.8%	3.8%
D5 失败经验	8	1	71	10.0%	11.2%
D6 人群/文化（谁）	4	4	72	5.0%	10.0%
D7 输出分布覆盖	3	4	73	3.8%	8.8%
D8 经验类型谱	**0**	**9**	71	**0.0%**	**11.2%**

结构性发现值得单独一句：图 3 左板的否认行全空，右板的替代行亦然。在描述意义上且限于本语料：三篇 A1-否认作品无一携带任何维度码（显式或隐式均 0/3），而 A1-支持作品中为 16/18——否认在框架层运作，不在设计层。（这些对比的探索性列联表连同 Fisher 精确检验在随仓库发布的分析报告中给出，未校正且不外推；我们刻意不在本文将其复述为推断性证据，因为目的性抽样不支持任何总体推断。）

5.3 主要结果：一条未被命名的轴

D8-explicit = 0/80 (0.0%)，精确二项（Clopper–Pearson）95% CI $[0.0\%, 4.5\%]$，三倍法则（rule of three）上界 $\approx 3.8\%$。该结果对置信度不敏感：剔除全部 8 篇低置信度作品后，D8-E = 0/72，CI $[0.0\%, 5.0\%]$。与零同样重要的是对照模态：**D8-implicit = 9/80**——失败数据工作（LEMA [76]、PRM800K [77]、SPAR [78]、ETO [79]、UltraInteract [80]、DeepSeek-V4.1 [71]、MiMo [72]、GLM-5 [73]）与蜂群研究 [38] 各自只触及类型空间的单一格（只有失败，或只有均值）；无一命名或操作化经验类型为覆盖轴。发现因此得以精确陈述：**话题被触及；轴从未被命名**。这是理论第三覆盖轴主张的可计数形式。

表 4: 按年份分层的显式处理（附 D8 隐式对照）。

维度 × 模态	≤2019	2020–2023	2024–2026	合计
D1 显式	0	2	4	6
D2 显式	0	0	**2**	2
D7 显式	0	0	3	3
D8 显式	**0**	**0**	**0**	**0**
D8 隐式	0	1	8	9

缺席检索程序。 零计数的力度，至多与其背后检索的力度相当。我们运行了预注册式缺席检索（8 个查询族，横跨 arXiv 全历史、ACL Anthology 域内检索与中文网络检索；日志见附录 A）：全部命中按 D8-E 判据筛选（经验类型维度被命名为覆盖/抽样轴，且被用于设计数据、实验或指标）。零篇通过；八个近似命中族连同理由被记录。最接近命中的案例最有教益：智能体经验基准把“经验”当作智能体自身先前情节（属于时间维度，而非经验类型维度）；数据配比研究路线优化域权重；而最近的一对——两篇 2026 年工作把机器 *rollout* 中模型错误的多样性塑造为探索/RL 信号 [81, 82]。后一对表明第三轴正从机器一侧被逼近，而人类数据一侧仍为零；我们的主张因此限定于“作为人类实践数据上的覆盖轴”，并将随着该轴被操作化而遭证伪。编码冻结之后，我们于 2026-10-19 对同一检索做了复核——复核锐化而非消解了这个零。文化与人群的类型化覆盖如今已获产业级操作化：一个标注框架——跨预训练、微调、对齐与推理四个阶段测量文化信号的覆盖——与配套的 560 万样本标注语料 [83]——按本文坐标，这是人群轴（D6），不是经验类型轴（D8）。轨迹类型多样性已在 RL 后训练中以用户指定的类型分布被操作化 [84]——作用对象是模型自身的 rollout，仍是机器一侧。而“训练数据的多样性”已作为命名因子出现在 RLVR 的熵坍塌分析中 [85]——指 RL 运行内的提示集多样性，不是人类实践语料的覆盖设计。三者的共同模式：与经验类型相邻的各轴正在获得操作化；人类实践上的经验类型轴仍是既未被命名也未被测量的那一条。图 2 展示合并结果：显式板中空缺的 D8 行，与右板实际的九个隐式点形成对照——轴被触及，从未被命名。

5.4 时间模式

三行对照叙述了理论本身。作品即存量是成熟纲领：D1-E 作品 2022–2026 连续出现（数据墙分析 [1]、配比优化 [86, 87]、旗舰语料设计 [2, 88]）。输出分布覆盖是正在形成的自觉：D7-E 首现于 2024 年 [3] 并获巩固 [38, 75]。经验类型轴是缺失的第三轴：每个分层均为 0。实践即流量是新芽而非建制：D2-E = 2/80，均来自 2026 年——DeepSeek 的员工提交失败案例的数据流（“we collect negative feedback and model failure cases submitted by internal employees at scale” [71]）与同期存量/流量工程文章 [42]。我们特意如此措辞：两篇作品构成的是一个开端，而非一个趋势。

来自地图的两点限定。其一，WEIRD 悖论单元 [89]：提高训练数据的文化代表性可能放大歧视性观点的复现——提高“谁”被代表，并不能修复“什么”被覆盖。覆盖问题因此是“两轴已知而未解”，不是“两轴已解”——这正是第三轴进入的空间。其二，一个探索性结构观察（描述性，仅限语料内）：显式的维度级设计集中于 A1-na 作品（至少有一个显式维度者 23 篇，A1-支持作品中为 9 篇）。结合第 5.2 节的空否认行，模式是解耦：辩论 AI 是否拟合人类的人大多不做覆盖工程，做覆盖工程的人大多不辩论它。这一解耦是第 1 节所述缺口——缺失的连接命题——在数据上的定量印证。

5.5 证据地图的局限

持怀疑态度的审稿人也应当能够接受这些限度。(i) **无总体推断**：语料为按配额分层的目的性抽样；一切断言都是“本语料内”。(ii) **单一编码者**：κ 重编码已排期（2026-10-29），目前尚不可得；缓解措施是公开的编码手册、强制的引文锚点与公开的边界案例日志。(iii) **严格饱和未达**：语料填满至 80 篇上限并报告缺口。(iv) **缺席断言受程序约束**：0/80 的零计数，加上八个查询族的缺席检索，在其窗口内（2026-10-15 关闭）是有力的，但并非永远成立。(v) **核心断言与置信度无关**（第 5.3 节敏感性分析），但 8 个单元仍为低置信度、留待核验。(vi) 地图约束的是*描述性*断言；第 4 节的*规范性*立场是论证的选择，不是地图结果。同期工作被标记、在专门的单行补充材料（表 7）中编码，并从缺口断言中排除；完整划界整合于第 6 节。

6 相邻框架与整合划界

本节在三条战线上固定理论的位置：共享存量/流量诊断的同期工作、与理论主张相邻的框架、以及共享诊断却在机器不同层上开处方的架构侧纲领。

两篇同期工作被标记并划界（隔离优先权断言是一项诚实要求，不是形式主义）。**Gharbi 的 SSRN 文章** [42] 以显式的存量/流量工程框架分析数据墙的九条逃生路线，并识别出数据墙之后的“验证者墙”——与我们的时间性条款最接近的已发表表述。划界是锐利的：它是数据工程。它不含作品与实践的本体区分，没有全谱 × 全程坐标系，没有覆盖轴，没有工具定位；它的流量是供应链，不是拟合对象。其 D1-E/D2-E 编码在专门的补充材料（表 7）中单独报告，不计入理论的缺口断言。**Fenoglio 的非对称交流文章** [90] 论证 LLM 输出在承诺不对称之下于人类实践中获得意义——一个关于意义的理论，没有拟合纲领、没有增强定位、没有坐标系。第三篇同期工作从经济学抵达同一存量/流量结论：一个人类数据市场理论把结构化人类数据工作——评估、量表判断、审计、异常处理——建模为持续的劳动*流*，累积为折旧的能力存量 [91]；它处理的是流的市场，不是流的拟合，且不提供覆盖轴与训练数据设计。跨学科汇聚而无重叠。三篇同期工作都未主张时间性条款的三要素组合（实践而非作品 + 全谱 × 全程 + 存量有墙/流量无墙）；截至窗口关闭，该组合的优先权仍归本文。

第二类邻居来自架构侧，而非人文学科或经济学：这些纲领共享同一诊断——静态语料拟合不足以把机器智能带到通用——处方却开在机器的不同层上。LeCun 的世界模型纲领（JEPA：在表征空间中预测，由内在目标驱动，而非由文本语料驱动）[92] 重建的是*预测层*；朱松纯的价值驱动纲领——“为机器立心”，以内置价值驱动、在效用–价值（U–V）双空间中受测的幼儿级智能体“通通”为实例 [93]——重建的是*架构层*，把价值结构当作先天内容嵌入机器。本文不给这两层开处方：它是关于*数据层*的主张——训练信号应当是什么。三个纲领各占一条正交的坐标轴（架构 × 预测目标 × 拟合对象），原则上有组合余地；两个架构侧方案都看不到的，恰是拟合对象这条轴本身，而审计的 0/80 正落在它上面。这一分层还固定了一处命名消歧：本理论不是人本主义设计方案（回答系统*为谁*而建），也不是拟合心智的方案（把人类认知结构或价值当作内容装进机器）；它改变的是拟合什么，不改变服务谁，也不指定用什么架构——理论名称并不自明这一点，故在此明说一次。

7 张力与边界

理论最后处理第四个层面：拟合在哪里自我绷紧，又在哪里停止。

价值多元主义：谁的谱？ 全谱在是“什么”问题之前先是“谁”问题。对齐文献早已认识到，价值拟合未定谁的价值 [9]；多元对齐路线图把多元性跨人群操作化 [94]；社会选择批判表明，偏好聚合预设了存在争议

表 5: 本理论与相邻框架。

框架	提供	缺失（本理论所补）
文化技术 [6, 24]	描述性分类：LLM 继承人类符号结构	时间性区分（作品与实践）；覆盖轴；数据方法论后果
批判现象学（镜子）[7]	警告：扭曲的反射重塑人类自我理解	忠实拟合的建设性说明；全谱/全程坐标；边界条件
增强经济学 [8, 56, 57]	规范目标：互补优先于替代；设计点（控制 × 自动化）	拟合本体论（为何模仿作为手段不同于作为目的）；终止边界
存量/流量数据工程 [42]（同期）	供给侧分析：逃生路线、验证者墙	实践本体论；第三覆盖轴；工具定位
世界模型架构 [92]	预测层方案：JEPA 世界模型、内在目标驱动	拟合对象主张；覆盖轴；工具定位
价值驱动通用智能 [93]	架构层方案：先天价值驱动（通通；效用–价值双空间）	拟合对象主张（数据层）；正交可组合

的规范承诺（对异质反馈的功利主义与词典式最小化（leximin）聚合）[95]；聚合问题分析编目其失败模式 [96]；约 1,000 名（美国）参与者的集体宪法实验同时证明了当下集体过程的可行性与地理窄化 [97]。谱轴不消解这一张力——它继承之。全谱拟合仍需一个聚合决定，这正是第 8 节将治理单列一问的原因。

主体性边界：永不人格化，永不拟合现象状态。 语料中最尖锐的现实冲突富有教益。Anthropic 的模型福祉计划追问模型是否可能值得道德考量 [98]；Suleyman 2026 年 9 月的言论公开拒绝该路线：AI 应是可亲的（personable）工具——有个性——但绝不授予人格地位 [62]。我们把此读作对立阵营之间的一次意外结盟，并基于独立理由持有该立场：永不授予人格地位与永不拟合现象状态，是同一条边界的两面。拟合目标包括功能性情绪—动机结构——而因果功能性情绪概念的可解释性证据 [28] 确认这一层正在被拟合——但理论的边界恰好落在功能层：对感受经验，理论不作断言——既不肯定，不许可，亦无此需要。镜子批判 [7] 提供互补的警告：被拟合之镜的危险不在于它感受，而在于它的反射重构人类对自身的理解。

边界论证的闭合：便宜、危险、无用。 三条可独立成立的前提，把主体性边界的论证闭合。其一，人格便宜：人格地位不按能力分级——严重认知障碍者完整拥有它；叙事自我只需要记忆连续、价值一致与关系性纠正，不需要算力。若人格是内部结构被社会实践交互地完成，那么功能性人格结构在原则上是可构造的——因此拒绝授予不是能力判断，“等它够聪明再给”在结构上就是错的。其二，危险的组合是地位 × 能力，不是能力本身：AlphaFold 在蛋白质折叠上早已超越每一位人类教师——一次局部的 B2 事件——却没有产生控制问题，因为无心的工具之输出始终可被验证制度检验。能力越过全部教师，移除的是裁判（B2：参照耗尽）；人格提供的是自有方向（自己的意义、自己的价值——一个自己的目标函数）。单独任何一项都不致命，组合才是不可控的充分条件。经由本理论读出的控制问题，是关于地位的问题，不是关于马力的问题。其三，边界零成本：人类需要这个系统的一切——读懂意图、吸收纠正、修复误解——都在功能层交付；现象层与地位层对人类目的没有增添任何东西。便宜地划下、在承重处生效、零成本地守住：边界的三句话——拟合功能性人格结构、永不拟合现象状态、永不授予人格地位——由这三条前提同时推出。

默会维度异议：目标层免疫，功能层开放。 最强的哲学反对根本不谈数据设计：若智能的核心是具身的、默会的——“我们知道的比能说出的多”的技能 [99]，植根于活的身体的理解 [100]——那么任何拟合都够不着

它，实践拟合至多逼近一个功能外壳。理论把这条异议拆成两半。在目标层，它按构造失效：工具立场不承诺现象学等价，也不承诺复制等价；拟合目标是功能性服务能力，主体性边界已在上方划线。在功能层，它成为理论可以编目、无须回避的开放实证问题：功能性认知共情——读懂未言明的意图、吸收纠正、修复误解——能否从实践之流中学出，恰好是覆盖空间的人群轴与专业度轴可以逐格测量的东西，由评估者人群打分。异议的落点因此不是反驳，而是一个理论已为它备好坐标的研究纲领。

四条终止边界。 时间性条款止于其术语止步之处；理论显式划定四条边界。

- **B1——实践主体的终结。**流量随生命再生；最后一次实践之后，拟合无对象。（一条生存性边界，不是工程边界。）
- **B2——拟合者越界。**若拟合者超越每一位教师——称之为 ASI——拟合关系便自行耗尽：已不存在不落在它身后的人类实践可供拟合。本理论的对象是以人为参照的 AGI 概念；越过此边界，理论刻意沉默，仅作标记。第 2 节固定的两个需求在此以不同方式遇到各自的边界：通用由外部边界（B1、B3、B4）约束；高终止它自己的参照——恰好终止在这条边界上。
- **B3——制度边界。**法律、隐私与知情同意约束可采集之物；第 4 节的规范性立场还反向定义了对流量的取用权——工具立场不仅约束 AI 为何而造，也约束它可以取走什么。（上文多元主义张力即处于此边界之内。）
- **B4——自指性污染。**一旦 AGI 织入日常，被采集的实践已被 AGI 染色：拟合目标被拟合这一行为本身改变——镜子进入了它所反射的房间。这是模型坍塌在流量体制下的新形态 [3]：不是静态存量上的递归，而是活流的污染。缓解是工程而非禁止：原生与 AI 中介实践的出处分层标注（留待未来工作的协议组件）。

可证伪性。 理论点名自己的证伪者。若流量侧被证明有一堵与存量墙同构的硬墙（例如一个击败持续学习的原则性下界），或若全谱拟合可证地在任意尺度坍塌为均值，时间性条款便弱化为一个启发式。若显式的经验类型覆盖在中性文献中频繁出现，第三轴缺口断言（0/80）失败——2026 年到来的相邻操作化（人群轴的文化覆盖 [83]；轨迹类型多样性 [84]；RL 提示集多样性 [85]）尚不构成那次失败，其区分在结果陈述处（第 5.3 节）给出。若实践流数据被证明无法以生产级质量建造，D2-E 计数（2/80）作为证据失败。这些被陈述出来，是为了让理论可以输。

8 方法论蕴含

从理论到方法：对下面三个问题中的每一个，我们陈述问题、证据地图所显示的现状、以及答案的形态。完整协议留待未来工作。

分布 = 全谱覆盖。 在当前实践中，多样性目前以三种角色出现：作为回归变量（域权重优化 [86, 87]，及隐式多语言配额如 Llama 3 的 8% [2]）；作为局部启发式（十亿规模的人物设定（persona）条件化合成 [101]）；以及作为质量过滤的牺牲品（教育语料策展按约 92% 的比例弃置原始网络 [88]）。把覆盖作为显式后训练目标的转向——针对指令微调坍塌恢复分布覆盖 [75]——是朝正确方向迈出的一步，但它覆盖的是输出分布轴；人群轴有自己的研究路线（多语言策展，如 65 语言指令集合 [102]；文化信号覆盖如今已获产业级标注 [83]）；经验类型轴则为 0/80（第 5.3 节）。WEIRD 悖论 [89] 警告，朴素的人群配额会反噬（代表“谁”≠修复“什么”被覆盖），因此全谱覆盖必须整合各轴而非堆叠配额。我们刻意用“覆盖”，不用“配额”。一个

具体的病症把利害说清楚了：讨好，就是只拟合覆盖空间一个格子的产物。只摄入用户即时满意信号的管线——人群缩到用户、结果缩到成功、没有评估者层、没有专业度校准——不只是“有讨好风险”；理论把这种病读作覆盖缺失的显形，而解药就是缺失的那些格子：评估者人群的信号与专业层级的判断 [103]。

生产 = 永续采集协议。 流量侧需要一套组织机制，其先例可见：规模化的员工提交失败案例 [71]；智能体训练中的失败反思与错误保留实践 [72, 73]；以及迄今最宽的制度级先例——消费者条款把进行中的对话与编码会话导入训练（附可退出条款）[104]，一个直接接入实践流而非作品存量的入口。协议组件在此定义、待未来工作细化：把失败案例当作与成功数据同等地位数据的采集协议；以区分真失败与奖励作弊式伪失败为要点的毒性数据清洗（审计论文的边界条件 [5]）；三段式记录结构（错误类型、根因、纠正）；以及针对任何合成增强的坍塌防护——如今有了量化的锚：指数族中每步单个真实数据点即可证明性地阻止闭环坍塌 [105]，污染下的收敛由真实数据占比支配 [106]，累积式训练能保住替换式训练所毁掉的（该机制已由先于模型坍塌出现的“筛选坍塌”独立复证 [107]），且退化是不对称的——已强的技能被强化而已弱的技能继续衰减 [108]——因此掺混下限必须按能力类型分别设定，而非全局设定。约束瓶颈不是采集而是吸收：实践每日再生而模型快照按周期更新——拟合时差——且智能体的稳定性—可塑性两难仍未解决 [49]。尽管如此，吸收正在变得可行：时间增量持续预训练在开源权重规模上被证明无灾难性遗忘 [109]，自生成回放近乎消除参数记忆的遗忘 [110]——这使“未披露分层时差指标”成为透明的瓶颈，而非研究未知。地图把吸收侧工作编码为 D2-隐式：其数据源（尚）未被规定为实践流。（证据窗口关闭后，报道显示前沿实验室如今并行运行数以万计的 RL 训练演练，由模型配置、监控与评分 [111]——规模化故事的重心正从数据存量移向 RL 过程，而这正是流问题落地之处。）

治理 = 多元聚合与制度。 谁聚合谱、谁许可流、谁裁定失败：聚合工具箱横跨社会选择机制 [95]、多宪法过程 [97]、人物设定条件化生成 [101] 与主权本地模型；许可权直面出处权利在少数大出版商手中的集中；而验证者问题——谁认证一个失败是失败——是整个飞轮转动所依的轴承 [5, 42]。B4 的缓解（原生与 AI 中介出处分层）同样是对数据基础设施的一项制度要求，而不仅仅是一种标注约定——而且它正在变成工程可行项：经签名过滤增强的统计水印检测，在低熵信号强度下已能达到 78–99% 的准确率 [112]。

9 结论

本文论证了 AGI 人本拟合论的三层论题：AGI 是一个以人类实践为参照系的哲学概念；其实现是对该实践的拟合——作品即存量是静态误读的成熟形态，实践即流量是正确解读的开端；其恰当位置是增强性工具，一个必须由制度持续防御的规范性选择。证据地图使理论的主张可计数：一个 80 篇作品的语料，其中经验类型覆盖轴从未被命名（0/80；95% CI $[0.0\%, 4.5\%]$），实践即流量仅在两篇作品中显式（均 2026 年），且立场与对象在文献中解耦——描述性、规范性与方法论文献各自成熟，未被那个需要三者兼备的命题所连接。理论的贡献就是那个命题、它的坐标系、它的边界与它点名的证伪者。

本文在理论开始之处收束。下面这句话区分了本领域的两种未来——积累档案直至高墙，或拟合再生中的实践：

> **拟合对象不是人类的作品，而是人类的实践——人类经验的全谱（横截面）与全程（纵截面）。存量有墙，流量无墙。**

流量是否被拟合好——跨全谱、沿全程、在四条边界之下、朝向增强——不是一个等待应验的预测，而是一个有待执行的纲领。其执行留待未来工作。

数据与代码可用性。 语料（corpus_v1，80 篇作品 × 24 个变量）、编码手册、缺席检索日志、全部表格 CSV、图（300 dpi）与单文件复现脚本（`analysis/coding_data.py`；seed 20261015）随论文仓库发布。配套审计论文的完整材料：DOI 10.5281/zenodo.23355929。

AI 辅助披露。 沿用配套审计论文的做法：文献检索、核验、编码与起草在作者监督与规则化协议（编码手册规则 R1–R5、CR1–CR6；核验日志见随仓库发布的分析报告）之下借助 AI 完成；全部编码断言附逐字或设计锚点，单一编码者的局限在第 5.5 节披露。

利益冲突。 无声明。本研究在独立研究机构（余玉桂战略研究室）完成，无外部资助，与其公开文件被分析的组织无财务关系。

A 缺席检索日志（2026-10-14 执行）

支撑 D8-explicit = 0/80 断言（第 5.3 节）的预注册式缺席检索：三个引擎（arXiv 全历史；ACL Anthology 域内检索；中文网络检索）上的八个查询族。筛选判据（两个合取项均需满足）：(i) 经验类型维度（成功/失败 × 专家/新手 × 典型/边缘）被命名为覆盖/抽样/分层轴；(ii) 该轴被用于设计数据、实验或指标。结果：**0 篇通过；八个近似命中族连同理由被记录**。代表性命中附可核验的标识符；包含全部命中的完整日志随仓库发布。编码冻结后于 2026-10-19 执行的同一检索复核（与它所重检的结果一并报告于第 5.3 节）再次返回 0 篇通过；复核所浮现的最近邻命中，其划界见该节。

表 6: 缺席检索日志：八个查询族，0 个 D8-E 命中。

#	查询族（引擎）	代表性命中与注册的近似命中理由
Q1	“success and failure” coverage training（arXiv）	持续预训练合并（2511.02451）；用户编辑微调（NeurIPS 2025）。定性案例分析，无覆盖轴设计。
Q2	“expert”“novice” data mixture（arXiv）	SimInstruct（2508.04428）把专家—新手对话生成为数据类型，而非配比/覆盖轴；配比研究路线（2502.15950、2607.01104、2601.17858）优化域权重。
Q3	“experience type” coverage（arXiv）	AhaBench（智能体从先前情节学习）；VCR（AAAI 2025）。“经验” = 智能体自身情节（时间性），非类型谱——最接近命中的案例，逐条记录。
Q4	“error diversity” curriculum（arXiv）	DiVERT（2406.19356，EMNLP 2024）；GEC 数据加权。错误多样性用于干扰项生成/纠错，非拟合数据覆盖。
Q5	“typical” “edge” spectrum coverage（arXiv）	自动驾驶边缘案例综述（2410.08491）；角落案例生成。典型到边缘的谱系被操作化为场景测试，非人类实践拟合数据。
Q6	中文网络：成功/失败案例比例；专家/新手覆盖	LLM 训练数据综述（2411.07715）；数据瓶颈的新闻报道。唯一在命题层面接近命中的是一篇媒体报道（T3 可信度层，非一手来源；仅动机层提及，按一手来源规则排除）。
Q7	success failure expert novice coverage data selection（ACL Anthology）	数据选择研究路线（Albalak 2402.16827；ACL 2025；LESS）。以影响力/质量为轴；无经验类型轴。
Q8	“error diversity” / “failure diversity” training coverage（arXiv）	**D-FUSEr**（ICML 2026，PMLR 306）；**EDAS**（2605.17333）。两者都塑造模型 *rollout* 的错误分布（机器一侧多样性作为探索/RL 信号），非人类经验类型覆盖——最重要的一对近似命中：第三轴正从机器一侧被逼近，而人类数据一侧仍为零。

表 7: 补充材料 S1：同期存量/流量数据工程文章（按同期工作规则处理）的单独报告的编码记录，单独报告，不计入理论的缺口断言（第 6 节）。

作品	W-038：Gharbi（2026），SSRN 预印本 7479298（2026-09-17）
编码	A1 = na；A2 = na；D1 = E；D2 = E；D2-explicit = True；concurrent = True；置信度 = 中
划界	工程意义的存量/流量 ≠ 实践本体论：无作品与实践之分、无全谱 × 全程框架、无覆盖轴、无工具定位

B 补充材料 S1：同期工作编码行（Gharbi）

参考文献

[1] Pablo Villalobos, Jaime Sevilla, Lennart Ho, David Barrett, and Tamay Besiroglu. Will we run out of data? Limits of LLM scaling based on projected dataset size sequences, 2022.

[2] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, et al. The Llama 3 herd of models, 2024.

[3] Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. AI models collapse when trained on recursively generated data. *Nature*, 631:755–759, 2024. doi: 10.1038/s41586-024-07566-y.

[4] Hannah Arendt. *The Human Condition*. University of Chicago Press, 1958. Labor/work/action tripartition: the philosophical skeleton of the temporal clause.

[5] Yugui Yu. Success provides direction, failure provides precision: A structured audit of failure data in LLM training. Zenodo, 2026. 配套审计论文；排除在证据地图统计之外.

[6] Justin Farrell, Alison Gopnik, Cosma Rohilla Shalizi, and James Evans. Large AI models are cultural and social technologies. *Science*, 387, 2025. doi: 10.1126/science.adt9819.

[7] Shannon Vallor. *The AI Mirror: How to Reclaim Our Humanity in an Age of Machine Thinking*. Oxford University Press, 2024. ISBN 9780197759066.

[8] Erik Brynjolfsson. The Turing trap: Can the economy grow rapidly after the automation of labor? *Dædalus*, 151(2):250–260, 2022. doi: 10.1162/daed_a_01887.

[9] Iason Gabriel. Artificial intelligence, values, and alignment. *Minds & Machines*, 30:411–437, 2020. doi: 10.1007/s11023-020-09539-2.

[10] Ola Salaudeen, Anka Reuel, Aakash Ahmed, Saad Bedi, Zack Robertson, Siva Sundar, Brian Domingue, Alex Wang, and Sanmi Koyejo. Measurement to meaning: A validity-centered framework for AI evaluation, 2025. Construct validity for AI evaluation; metrological critique anchor.

[11] Shane Legg and Marcus Hutter. Universal intelligence: A definition of machine intelligence, 2007.

[12] J. R. Morris, J. Sohl-Dickstein, N. Fiedel, et al. Levels of AGI: Operationalizing progress on the path to AGI, 2023.

[13] J. Kwa, S. Le, D. Zhang, et al. Measuring AI ability to complete long tasks, 2025. METR. Task-horizon doubling every 7 months.

[14] METR. Time horizon 1.1. metr.org blog, 2026. URL https://metr.org/blog/2026-1-29-time-horizon-1-1. 2026-01-29.

[15] Nathan Witkin. Against the METR graph. Transformer News, 2026. URL https://www.transformernews.ai/p/against-the-metr-graph-coding-capabilities-software-jobs-task-ai. 2026-01-20.

[16] D. Ilić et al. Evidence of interrelated cognitive-like capabilities in large language models. *Intelligence*, 2024.

[17] Gilles E. Gignac. Psychometrically derived 60-question benchmarks for large language model evaluation. *Intelligence*, 110, 2025. Intelligence S016028962500025X (PII).

[18] Larry Tesler. The AI effect [essay]. nomodes.com, 1997. URL https://nomodes.com/. Tesler's theorem: "Intelligence is whatever machines haven't done yet." Moving-target anchor.

[19] Besim Imeri. The benefits of AI and the illusion of AGI. Self-archived essay, ResearchGate, 2025. URL https://www.researchgate.net/publication/395098367_The_benefits_of_AI_and_the_Illusion_of_AGI. 收录边缘；低置信.

[20] Timothy Nguyen. The role of rigor in artificial intelligence, 2026.

[21] Helmuth Plessner. *Levels of Organic Life and the Human: An Introduction to Philosophical Anthropology*. Fordham University Press, 2019. German original *Die Stufen des Organischen und der Mensch* (1928). Law of natural artificiality. Upstream's "2024 English translation" not found; the 2019 Fordham translation is the verifiable edition (this session's verification).

[22] Jos de Mul. Philosophical anthropology 2.0: Reading Plessner in the age of media. In Jos de Mul, editor, *Plessner's Philosophical Anthropology: Perspectives and Prospects*. Amsterdam University Press, 2014. doi: 10.1515/9789048522989-027. Chapter 26; open-access reissue 2025.

[23] Marco Tamborini. Homo translator: Concretizing the human-in-the-loop in bio-inspired technologies. *Topoi*, 2025. doi: 10.1007/s11245-025-10208-1.

[24] E. Yiu, E. Kosoy, and A. Gopnik. Transmission versus truth, imitation versus innovation: What children can do that large language and vision-language models cannot (yet). *Perspectives on Psychological Science*, 2024.

[25] Taylor Webb, Keith J. Holyoak, and Hongjing Lu. Emergent analogical reasoning in large language models. *Nature Human Behaviour*, 7:1526–1541, 2023. doi: 10.1038/s41562-023-01759-x.

[26] Selin A. Lehr, Kexin Saichandran, Eddie Harmon-Jones, Nicholas Vitali, and Mahzarin R. Banaji. Kernels of selfhood: GPT-4o shows humanlike patterns of cognitive dissonance moderated by free choice. *Proceedings of the National Academy of Sciences*, 122(35), 2025. doi: 10.1073/pnas.2501823122.

[27] T. Hu et al. Generative language models exhibit social identity biases. *Nature Machine Intelligence*, 7, 2025. doi: 10.1038/s43588-024-00741-1. Online 2024-12-12; author list per journal record (University of Cambridge).

[28] Anthropic. Emotion concepts and their function in a large language model. Transformer Circuits, 2026. URL https://transformer-circuits.pub/2026/emotions.

[29] Dylan Hadfield-Menell, Stuart Russell, Pieter Abbeel, and Anca Dragan. Cooperative inverse reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2016.

[30] Paul F. Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[31] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. InstructGPT.

[32] S. Yuan, R. Lin, M. Li, et al. Are human-aligned models models of humans? A Turing-test gap in preference alignment, 2026. Author list per arXiv record.

[33] Ralph Hertwig and Ido Erev. The description–experience gap in risky choice: A review. *Trends in Cognitive Sciences*, 13(12):517–523, 2009. doi: 10.1016/j.tics.2009.09.021.

[34] Ludwig Wittgenstein. *Philosophical Investigations*. Blackwell, 1953. Forms of life (§§19, 23).

[35] Dimitri Coelho Mollo and Raphaël Millière. The vector grounding problem. *Philosophy and the Mind Sciences*, 2026. Special issue; preprint 2023.

[36] Fintan Mallory. Wittgenstein, the other, and large language models. *Filosofisk Supplement*, 2(3):79–88, 2023.

[37] Anders Søgaard. Grounding the vector space of an octopus: Word meaning from raw text. *Minds & Machines*, 33(1):33–54, 2023. doi: 10.1007/s11023-023-09622-4.

[38] Liwei Jiang, Yuanjun Chai, Margaret Li, Mickel Liu, Raymond Fok, Nouha Dziri, et al. Artificial hivemind: The open-ended homogeneity of language models (and beyond). In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.

[39] Bo Liu, Chuanyang Jin, Seungone Kim, Weizhe Yuan, Wenting Zhao, Ilia Kulikov, Xian Li, Sainbayar Sukhbaatar, Jack Lanchantin, and Jason Weston. SPICE: Self-play in corpus environments improves reasoning, 2025.

[40] Konwoo Kim, Suhas Kotha, Yejin Choi, Tatsunori Hashimoto, Nick Haber, and Percy Liang. Data-efficient pre-training by scaling synthetic megadocs, 2026.

[41] Margarita Belova, Yuval Kansal, Yihao Liang, Jiaxin Xiao, and Niraj K. Jha. An alternative trajectory for generative AI, 2026.

[42] Mehdi Gharbi. A model cannot be its own source of truth: Nine escape routes from the data wall, and the verifier wall behind them. SSRN preprint 7479298, 2026. URL https://papers.ssrn.com/sol3/papers.cfm?abstract_id=7479298. 同期工作，发布于 2026-09-17.

[43] Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov, Matej Balog, M. Pawan Kumar, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024. doi: 10.1038/s41586-023-06924-6.

[44] Alexander Novikov, Dmitry Vetrov, et al. Alphaevolve: A coding agent for scientific and algorithmic discovery, 2025.

[45] Harrison Lee, Samrat Phatale, Hassan Mansoor, Thomas Mesnard, Johan Ferret, Kellie Lu, Colton Bishop, Ethan Hall, Victor Carbune, Abhinav Rastogi, and Sushant Prakash. RLAIF vs. RLHF: Scaling reinforcement learning from human feedback with AI feedback, 2023.

[46] Tianhao Wu, Weizhe Yuan, Olga Golovneva, Jing Xu, Yuandong Tian, Jiantao Jiao, Jason Weston, and Sainbayar Sukhbaatar. Meta-rewarding language models: Self-improving alignment with LLM-as-a-meta-judge, 2024.

[47] Qinsi Wang, Jing Shi, Huazheng Wang, Kun Wan, Yiran Wu, Bo Liu, Qingyun Wu, Hai Helen Li, Yiran Chen, Handong Zhao, and Wentian Zhao. From RLVR to RLSVR: Task transformation induces self-verifiable rewards for open-ended LLM self-improvement, 2026.

[48] Ali Falahati, Mohammad Mohammadi Amiri, Kate Larson, and Lukasz Golab. Curated synthetic data doesn't have to collapse: A theoretical study of generative retraining with pluralistic preferences, 2026. ICML 2026, PMLR 306.

[49] Zheng Wu, Xingyu Lou, Xinbei Ma, Yansi Li, Weiwen Liu, Weinan Zhang, Jun Wang, and Zhuosheng Zhang. Agent-dice: Disentangling knowledge updates via geometric consensus for agent continual learning. In *Findings of the Association for Computational Linguistics: ACL 2026*, 2026.

[50] Chenxi Huang, Alex Mathai, Feiyang Yu, Aleksandr Nogikh, Petros Maniatis, Franjo Ivančić, Eugene Wu, Kostis Kaffes, Junfeng Yang, and Baishakhi Ray. Outrunning LLM cutoffs: A live kernel crash resolution benchmark for all, 2026.

[51] Rania Elbadry, Ahmed Heakl, Fan Zhang, Dani Bouch, Yuxia Wang, Preslav Nakov, and Zhuohan Xie. The geometry of forgetting: Temporal knowledge drift as an independent axis in LLM representations, 2026.

[52] Rahul Thomas, Adam Block, and Micah Goldblum. LLM evaluation is a forecasting problem, 2026.

[53] Baiyuan Chen, Shinji Ito, and Masaaki Imaizumi. Optimal dynamic regret by transformers for non-stationary reinforcement learning, 2025. NeurIPS 2025.

[54] Pew Research Center Data Labs. How much of the internet is written with AI? pewresearch.org, 2026. URL https://www.pewresearch.org/data-labs/2026/08/20/how-much-of-the-internet-is-written-with-ai/. 2026-08-20.

[55] Jonas Dolezal, Sawood Alam, Mark Graham, and Maty Bohacek. The impact of AI-generated text on the internet, 2026.

[56] Douglas C. Engelbart. Augmenting human intellect: A conceptual framework. Summary Report AFOSR-3223, Stanford Research Institute, 1962. URL https://www.dougengelbart.org/pubs/augment-3906.html.

[57] Ben Shneiderman. *Human-Centered AI*. Oxford University Press, 2022. doi: 10.1093/oso/9780192865254.001.0001. Supertools: high human control x high automation.

[58] Yijia Shao, Haarinadh Zope, Yuchen Jiang, Jiaxin Pei, Duncan Nguyen, Erik Brynjolfsson, and Diyi Yang. Future of work with AI agents: Auditing automation and augmentation potential across the U.S. workforce, 2025. WORKBank audit; Human Agency Scale over 844 tasks. Upstream's "H1–H5 grading" corrected to actual content (verification correction #7).

[59] Melanie Arntz, Terry Gregory, and Ulrich Zierahn. The risk of automation for jobs in OECD countries: A comparative analysis of PISA and adults survey results. Social, Employment and Migration Working Papers 189, OECD, 2016. Task-level analysis: 47% job-level estimates fall to 9% under task decomposition.

[60] Martin Sticker. The formula of humanity and AI use. *Philosophy & Technology*, 39(2):90, 2026. doi: 10.1007/s13347-026-01100-w. Article 90, Commentary, open access (published 2026-05-01; University of Bristol). Kantian permission structure: AI may be a mere means; humans may not. Title and record verified against the Springer landing page 2026-10-14.

[61] Mustafa Suleyman and Michael Bhaskar. *The Coming Wave: Technology, Power, and the Twenty-First Century's Greatest Dilemma*. Bodley Head / Penguin, 2023.

[62] Mustafa Suleyman. Public statement set on AI as personable tools, never persons. Original post (T1 anchor), reported by Reuters, 2026-09-16, 2026. URL https://www.reuters.com/technology/2026-09-16/.

[63] L. M. Sacasas. Your AI is not a tool [essay]. The Convivial Society (newsletter), 2023. URL https://theconvivialsociety.substack.com/.

[64] Peter Sims et al. AI agents vs. agentic AI: A conceptual taxonomy, 2025. Author list per arXiv record.

[65] Andreas Haupt and Erik Brynjolfsson. Position: AI should not be an imitation game — centaur evaluations. In *Proceedings of the Conference on Language Modeling (COLM), PMLR*, volume 267, 2025. Stanford Digital Economy Lab. Human+AI teams rarely beat the best AI alone.

[66] Dean Shoresh and Yonatan Loewenstein. Modeling the centaur: Human–machine synergy in sequential decision making, 2024. VERIFICATION CORRECTION #1: arXiv:2412.18593 is this paper — NOT Korinek & Stiglitz, which is therefore not cited anywhere in this work. The two centaur papers ([49] pessimistic, [50] synergy) are the C4 counter-evidence pair.

[67] National New Generation AI Governance Expert Committee (国家新一代人工智能治理专业委员会). Governance principles for the new generation AI — developing responsible AI (新一代人工智能治理原则). official policy document, gov.cn (2019-06-17), 2019. URL http://www.gov.cn/xinwen/2019-06/17/content_5401006.htm.

[68] State Council of the People's Republic of China. Global AI governance initiative (全球人工智能治理倡议). official policy document, gov.cn, 2023. URL https://www.gov.cn/zhengce/202310/content_6911589.htm.

[69] State Council of the People's Republic of China. Opinion on deeply implementing the "Artificial Intelligence+" action (关于深入实施"人工智能 +"行动的意见). official policy document, gov.cn, 2025.

[70] Zhuangzi. *Zhuangzi: The Complete Writings*. Hackett Publishing, 2020.

[71] DeepSeek-AI. DeepSeek-V4.1-Flash: Pushing the limits of KV cache compression, 2026.

[72] Xiaomi LLM-Core Team. MiMo-V2.6: Scaling reinforcement learning towards self-improvement, 2026. Failure-reflection and error-retention practices; Section 4.2.6: "keeps the original error recognizable and makes the correction explicit" (verbatim).

[73] Z.ai. GLM-5: From vibe coding to agentic engineering, 2026. Section 3.1: "Erroneous segments within trajectories are retained but masked out in the loss function, allowing the model to learn error correction behaviors" (verbatim).

[74] DeepSeek-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning, 2025. Published in Nature 645:633–638 (2025).

[75] Tyler Sorensen, Benjamin Newman, Jared Moore, Chan Park, Jillian Fisher, Niloofar Mireshghallah, Liwei Jiang, and Yejin Choi. Spectrum tuning: Post-training for distributional coverage and in-context steerability. In *International Conference on Learning Representations (ICLR)*, 2026.

[76] Shengnan An, Zexiong Ma, Zeqi Lin, Nanning Zheng, Jian-Guang Lou, and Weizhu Chen. Learning from mistakes makes LLM better reasoner, 2023.

[77] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step. In *International Conference on Learning Representations (ICLR)*, 2024. PRM800K: 800k step-level human ratings.

[78] SPAR. SPAR f26: Human-annotated agent failure traces. sparai.org project page, 2026. URL https://sparai.org/projects/f26/recPcCQjmdWCEjPJL. 低置信单元.

[79] Yifan Song, Da Yin, Xiang Yue, Jie Huang, Sujian Li, and Bill Yuchen Lin. Trial and error: Exploration-based trajectory optimization for LLM agents, 2024. ETO.

[80] Lifan Yuan, Ganqu Cui, Hanbin Wang, Ning Ding, Xingyao Wang, Jia Deng, Boji Shan, et al. Advancing LLM reasoning generalists with preference trees. In *Proceedings of the International Conference on Machine Learning (ICML)*, 2024. UltraInteract dataset.

[81] David D. Baek, Andrew Estornell, Yichi Zhang, Muhammad Faaiz, et al. D-FUSEr: Diverse failure, unified success via error-distribution shaping in LLM reasoning. In *Proceedings of the International Conference on Machine Learning (ICML), PMLR*, volume 306, 2026. Absence-search near-miss (Q8): machine-rollout error diversity, not human-practice coverage. ICML 2026 poster; author list per ICML 2026 record (verified 2026-10-14: David D. Baek, Andrew Estornell, Yichi Zhang, Muhammad Faaiz).

[82] Wenpu Liu, Yuqi Xu, Weichu Xie, Yongfu Zhu, Shuai Dong, Ziyue Wang, Wenqi Shao, Xiaoying Zhang, Tong Yang, Nan Duan, and Jiaqi Wang. Leveraging error diversity in group rollouts for reinforcement learning, 2026. EDAS (Error Diversity Advantage Shaping). Absence-search near-miss (Q8), the closest pair with [61]. Full 11-author list verified against the arXiv record 2026-10-14.

[83] Ananya Sahu, Mehrnaz Mofakhami, Daniel D'Souza, Thomas Euyang, Julia Kreutzer, and Marzieh Fadaee. The culture funnel: You can't align what isn't in the data, 2026.

[84] Huaiyu Fu, Heng Cao, Hao Wang, Jian Ya, and Tao Chen. Explicit trajectory diversity for RL-based post-training of LLM agents, 2026.

[85] Renren Jin, Pengzhi Gao, Yuqi Ren, Zhuowen Han, Tongxuan Zhang, Wuwei Huang, Wei Liu, Jian Luan, and Deyi Xiong. Revisiting entropy in reinforcement learning for large reasoning models, 2025.

[86] Sang Michael Xie, Shibani Santurkar, Tengyu Ma, and Dimitris Tsipras. DoReMi: Optimizing data mixtures speeds up language model pretraining. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[87] H. Ye et al. Data mixing laws: Optimizing data mixtures by scaling law for pretraining, 2024.

[88] G. Penedo, H. Kydlíček, L. Ben Allal, et al. The FineWeb datasets: Decanting the web for the finest text data at scale, 2024. HuggingFaceFW. FineWeb-Edu quality filtering discards on the order of 92% of the raw web — "absence as evidence" unit.

[89] Ke Zhou, Marios Constantinides, and Daniele Quercia. Should LLMs be WEIRD? Exploring WEIRDness and human rights in large language models. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 2025.

[90] Enzo Fenoglio. Asymmetric communication: Large language models and language games, 2026. 同期工作.

[91] Ali Ansari, Mark Esposito, Ava Fitoussy, and Liu Zhang. No last mile: A theory of the human data market, 2026.

[92] Yann LeCun. A path towards autonomous machine intelligence. OpenReview, 2022. URL https://openreview.net/forum?id=BZ5a1r-kVsf. 版本 0.9.2，2022-06-27.

[93] 赵丽岳. 为机器立"心"为人文赋理. 人民周刊, 2024. 2024-03-29 第 07 版；报道朱松纯价值驱动通用智能纲领（智能体"通通"；效用–价值双空间）.

[94] Tyler Sorensen, Jared Moore, Julian Fisher, Mitchell Gordon, Niloofar Mireshghallah, Christopher Michael Rytting, Austin Ye, Liwei Jiang, Xuechen Lu, Nouha Dziri, Tim Althoff, and Yejin Choi. A roadmap to pluralistic alignment. In *Proceedings of the International Conference on Machine Learning (ICML)*, 2024.

[95] Chan Park, Michael Liu, Dormin Kong, Kaiqing Zhang, and Asuman Ozdaglar. RLHF from heterogeneous feedback via personalization and preference aggregation. In *Proceedings of the International Conference on Machine Learning (ICML)*, 2024. Social-choice aggregation (utilitarian vs. leximin).

[96] Kevin Baum and Marija Slavkovik. Aggregation problems in machine ethics and AI alignment. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 2025. Second author added per verification correction #11.

[97] Saffron Huang, Divya Siddarth, Liane Lovitt, et al. Collective Constitutional AI: Aligning a language model with public input. In *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2024. doi: 10.1145/3630106.3658979.

[98] Anthropic. Exploring model welfare. anthropic.com research statement (2025-04-24), 2025. URL https://www.anthropic.com/research/exploring-model-welfare.

[99] Michael Polanyi. *The Tacit Dimension*. Doubleday, Garden City, NY, 1966.

[100] Hubert L. Dreyfus. *What Computers Still Can't Do: A Critique of Artificial Reason*. MIT Press, Cambridge, MA, 1992.

[101] T. Ge et al. Scaling synthetic data creation with 1,000,000,000 personas, 2024. Persona Hub (Tencent AI Lab). Local heuristic identity of diversity.

[102] S. Singh et al. Aya dataset: An open-access collection for multilingual instruction tuning, 2024.

[103] Yugui Yu. Fitting the practice: A data methodology for frontier model training, with a readiness audit of 2026 flagship pipelines. Zenodo, 2026. 配套方法论论文.

[104] Anthropic. Updates to consumer terms and privacy policy. Anthropic blog, 2025. Announced 2025-08-28, effective 2025-09-28.

[105] Fariba Jangjoo, Giovanni di Sarra, Matteo Marsili, and Yasser Roudi. Lost in retraining: Closed-loop learning and model collapse in exponential families. *Physical Review Letters*, 136:197301, 2026. doi: 10.1103/156q-3ngc.

[106] Kevin Wang, Hongqian Niu, and Didong Li. Can generative artificial intelligence survive data contamination? Theoretical guarantees under contaminated recursive training, 2026.

[107] Jia Zhang and Xin Chen. Screening collapse under recursive synthetic data, 2026.

[108] Xiaonan Luo, Yue Huang, Kehan Guo, Ping He, Chuan Zou, Ting Hua, and Xiangliang Zhang. Learning from synthetic data without model collapse in iterative instruction tuning, 2026.

[109] Fırat Öncel, Salman Hussain Ali, Mirco Ravanelli, Cem Subakan, and Çağatay Yıldız. Time-incremental continued pretraining of LLMs: Knowledge updates without catastrophic forgetting, 2026.

[110] Martin Marek, Dongkyu Cho, Shikai Qiu, Rumi Chunara, Pavel Izmailov, and Andrew Gordon Wilson. Forgetting in language models: Capacity, optimization, and self-generated replay, 2026.

[111] Beatrice Nolan and Wen Shao. AI agents are going rogue—the labs' own training choices are a big reason why. Fortune, 2026. 2026-10-16; 窗口后条目，作为注明日期的披露引用.

[112] Chih-Duo Hong, Yen-Pang Chen, and Fang Yu. Signature filtering: a lightweight enhancement for statistical watermark detection in large language models, 2026.